

Báo cáo Phân tích Khám phá Dữ liệu (EDA)

Bộ dữ liệu Iris — Đồ án "EDA Thám Tử Dữ Liệu"

1. Giới thiệu bộ dữ liệu

Bộ dữ liệu **Iris** là một trong những dataset kinh điển và nổi tiếng nhất trong lĩnh vực học máy, được nhà thống kê Ronald Fisher công bố lần đầu vào năm 1936 để minh họa cho phương pháp phân tích thống kê (discriminant analysis). Dataset gồm 150 mẫu hoa Iris (hoa diên vĩ), chia đều cho 3 loài: *Iris setosa*, *Iris versicolor* và *Iris virginica*, mỗi loài đúng 50 mẫu.

Mỗi mẫu được đo 4 đặc trưng số (numerical, đơn vị cm): chiều dài đài hoa (`SepalLengthCm`), chiều rộng đài hoa (`SepalWidthCm`), chiều dài cánh hoa (`PetalLengthCm`) và chiều rộng cánh hoa (`PetalWidthCm`). Cột thứ 5, `Species`, là nhãn loài (categorical) — chính là target nếu xây dựng bài toán phân loại (classification). Ngoài ra còn có cột `Id` chỉ đơn thuần là số thứ tự, không mang ý nghĩa phân tích.

Khác với 2 dataset đã phân tích trước đó trong đồ án (Titanic, Housing), Iris có 2 điểm khác biệt quan trọng: dữ liệu hoàn toàn **sạch** (không có missing value), và bài toán ở đây là **phân loại nhiều lớp** (multi-class classification) thay vì hồi quy (regression) như Housing. Vì vậy, dataset này rất phù hợp để rèn luyện kỹ năng tìm insight và trực quan hóa dữ liệu mà không bị phân tán bởi bước làm sạch dữ liệu.

2. Bước 1 — Đọc và khám phá tổng quan

Dữ liệu được đọc bằng `pd.read_csv()`, sau đó khám phá nhanh bằng `head()` (xem 5 dòng đầu) và `info()` (xem kiểu dữ liệu và số lượng giá trị non-null của từng cột).

Kết quả `info()` : dataset có 150 dòng, 6 cột — `Id` (int64), `SepalLengthCm`, `SepalWidthCm`, `PetalLengthCm`, `PetalWidthCm` (đều float64), và `Species` (object). Tất cả 6 cột đều có đủ **150 giá trị non-null**.

3. Bước 2 — Phân loại biến categorical / numerical

Ở Housing, bước này đòi hỏi viết code riêng vì có "bẫy": cột số nhưng thực chất là mã phân loại (ví dụ `MSSubClass`), và nhiều cột `object` cần ép kiểu `category` để xử lý missing values sau đó. Với Iris, không có bẫy nào như vậy — `Species` đã tự động đúng kiểu `object`, 4 cột đo lường đều là `float64` thật sự, nên bước này coi như hoàn tất ngay từ kết quả `info()` ở Bước 1, không cần code xử lý thêm. Cột `Id` được loại khỏi phân tích vì không mang ý nghĩa thống kê.

4. Bước 3 — Xử lý missing values

Kết quả `info()` cho thấy cả 6 cột đều có đủ 150/150 giá trị non-null — nghĩa là dataset **không có bất kỳ missing value nào**. Đây là điểm khác biệt lớn so với Housing/Titanic, nơi phải xử lý hàng chục cột thiếu dữ liệu. Với Iris, bước này không cần thực hiện thao tác gì.

5. Bước 4 — Phân tích target (Species)

5.1. Kiểm tra cân bằng lớp

Dùng `train['Species'].value_counts()` để đếm số mẫu mỗi loài:

Loài	Số mẫu
Iris-setosa	50
Iris-versicolor	50
Iris-virginica	50

Dữ liệu hoàn toàn cân bằng giữa 3 lớp — không cần các kỹ thuật xử lý mất cân bằng dữ liệu (imbalanced data) khi xây dựng model phân loại sau này.

5.2. So sánh thống kê giữa các loài

Dùng `train.groupby('Species').mean()` (và `.describe()` để xem chi tiết hơn) nhằm so sánh trung bình từng đặc trưng theo từng loài, thay vì tính gộp chung cả 150 mẫu:

Loài	SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm
Iris-setosa	~5.01	~3.42	~1.46	~0.24
Iris-versicolor	~5.94	~2.77	~4.26	~1.33
Iris-virginica	~6.59	~2.97	~5.55	~2.03

Insight: Chênh lệch giữa 3 loài ở `PetalLengthCm` và `PetalWidthCm` rất rõ rệt — setosa có cánh hoa nhỏ hơn hẳn (gần gấp 3 lần so với virginica), trong khi 2 cột sepal có chênh lệch nhỏ hơn nhiều. Đây là dấu hiệu đầu tiên cho thấy petal (cánh hoa) là đặc trưng nhận dạng loài mạnh nhất.

6. Bước 5 — Tìm insight ẩn (Correlation & Outliers)

6.1. Phân tích tương quan (Correlation)

Dùng `train.corr(numeric_only=True)` để tính hệ số tương quan giữa các cột số, sau đó trực quan hóa bằng `sns.heatmap(corr, annot=True)` để dễ đọc hơn so với bảng số thuần túy.


Các cặp tương quan đáng chú ý (bỏ qua cột `Id`):

- `PetalLengthCm` & `PetalWidthCm` = **0.9628** — tương quan cực mạnh: cánh hoa càng dài thì gần như chắc chắn càng rộng theo.
- `SepalLengthCm` & `PetalLengthCm` = **0.8718** — tương quan mạnh: hoa có đài dài thì cánh cũng thường dài theo.
- `SepalLengthCm` & `PetalWidthCm` = **0.8180** — cùng logic: kích thước tổng thể của hoa có xu hướng lớn cùng nhau.
- `SepalWidthCm` với các cột còn lại: **-0.10 đến -0.42** (toàn bộ âm, dù yếu) — chiều rộng đài hoa có xu hướng *ngược chiều* với các kích thước còn lại, là cột duy nhất "lệch pha" so với phần còn lại của dataset.


Insight: 3 trong 4 đặc trưng (sepal length, petal length, petal width) đo cùng một xu hướng — "kích thước tổng thể của hoa". Riêng `SepalWidthCm` hoạt động độc lập/ngược chiều, nên mang thông tin không trùng lặp với 3 cột kia.

6.2. Phát hiện Outliers (giá trị bất thường)


Outliers được phát hiện bằng **boxplot** vẽ riêng cho từng cột, chia theo `Species` (dùng `sns.boxplot(x='Species', y=<cột>, data=train)`). Các điểm nằm ngoài "râu" (whiskers) của hộp được xem là outliers.




Boxplot PetalLengthCm theo loài



Boxplot SepalLengthCm theo loài



Boxplot SepalWidthCm theo loài



Boxplot PetalWidthCm theo loài

Cột	Outliers phát hiện	Mức độ chồng lấn giữa 3 loài
SepalLengthCm	Không có	Versicolor và virginica chồng lấn khá nhiều
SepalWidthCm	2 điểm ở virginica (1 cao ~3.8, 1 thấp ~2.0)	Chồng lấn nhều nhất — cả 3 loài gần như đề lên nhau
PetalLengthCm	3 điểm ở setosa, 1 điểm ở versicolor	Hầu như không chồng lấn — 3 hộp tách biệt rõ
PetalWidthCm	2 điểm ở setosa	Hầu như không chồng lấn , tương tự petal length


Insight: Dù có vài outlier lẻ tẻ ở từng cột, mức độ ảnh hưởng không đáng kể vì hộp (box) của 3 loài ở PetalLengthCm / PetalWidthCm vẫn tách biệt hoàn toàn. Ngược lại, SepalWidthCm là cột có mức chồng lấn

nghiêm trọng nhất giữa các loài, khớp với kết quả phân tích correlation ở trên.

7. Bước 6 — Trực quan hóa phân phối (Histogram)

Dùng `sns.histplot(data=train, x=<cột>, hue='Species', kde=True)` để vẽ phân phối từng cột, tô màu riêng theo loài và thêm đường cong mật độ (KDE) để thấy rõ hình dạng phân phối.


7.1. PetalLengthCm



Hình 1 — Phân phối PetalLengthCm theo từng loài

Setosa có một đỉnh (peak) rất cao và hẹp quanh giá trị 1-1.5, cho thấy độ biến thiên rất thấp, và tách biệt hoàn toàn khỏi 2 loài kia (có khoảng trống từ ~2 đến ~3 không có mẫu nào). Versicolor và virginica có đỉnh lần lượt quanh 4-4.5 và 5.5-6, với 2 đường cong KDE giao nhau nhẹ quanh giá trị 5 — đây là vùng "mập mờ" khó phân biệt chắc chắn 2 loài này chỉ dựa vào cột này.


7.2. SepalLengthCm



Hình 2 — Phân phối SepalLengthCm theo từng loài

3 đường cong chồng lẫn khá nhiều, đặc biệt versicolor (đỉnh ~5.8) và virginica (đỉnh ~6.5) giao nhau trên một đoạn rộng (5.5-7). Setosa (đỉnh ~5.0) tách biệt hơn nhưng vẫn chồng lẫn nhẹ với phần đầu của versicolor quanh 5.0-5.5.


7.3. SepalWidthCm



Hình 3 — Phân phối SepalWidthCm theo từng loài

Đây là cột chồng lấn **nhều nhất** trong cả 4 cột. Versicolor và virginica gần như trùng khít lên nhau hoàn toàn (cả 2 đỉnh quanh 2.8-3.0, hình dạng gần giống hệt nhau) — nếu chỉ dựa vào cột này, gần như không thể phân biệt được versicolor với virginica. Setosa nhích cao hơn một chút (đỉnh ~3.3-3.5) nhưng vẫn chồng lấn kha khá với 2 loài kia.

7.4. PetalWidthCm



Hình 4 — Phân phối PetalWidthCm theo từng loài

Có pattern giống hệt `PetalLengthCm` — setosa tách biệt hoàn toàn (0.1-0.4), versicolor (1.0-1.8) và virginica (1.4-2.5) chỉ chồng lấn nhẹ ở đoạn 1.4-1.8.

8. Kết luận tổng hợp

Qua toàn bộ quá trình phân tích — từ thống kê mô tả, correlation, outliers, đến phân phối — có thể xếp hạng khả năng phân biệt 3 loài hoa của từng đặc trưng như sau, từ mạnh nhất đến yếu nhất:

Hạng	Đặc trưng	Nhận xét
1	PetalLengthCm / PetalWidthCm	Phân biệt mạnh nhất — 3 loài gần như tách biệt hoàn toàn ở cả boxplot lẫn histogram, đặc biệt setosa tách biệt tuyệt đối.
2	SepalLengthCm	Phân biệt trung bình — tách được setosa nhưng versicolor/virginica còn chồng lẫn đáng kể.
3	SepalWidthCm	Phân biệt yếu nhất — versicolor và virginica gần như không thể phân biệt chỉ dựa vào cột này; cũng là cột duy nhất có tương quan âm với các cột khác.

Kết luận này nhất quán xuyên suốt cả 3 phương pháp phân tích độc lập (thống kê mô tả theo nhóm, ma trận tương quan, và trực quan hóa phân phối) — cho thấy đây là một insight đáng tin cậy của dataset Iris: **kích thước cánh hoa (petal) là đặc trưng quan trọng và đáng tin cậy nhất để nhận dạng loài hoa Iris**, trong khi kích thước đài hoa (sepal), đặc biệt là chiều rộng, đóng vai trò hỗ trợ yếu hơn nhiều.